

공유오피스 결제 전환 증대를 위한 3일 체험 프로모션 최적화 전략 제안

: 머신러닝 모델을 활용한 요인 분석을 중심으로

김나은, 문상혁, 박철, 최지원

목 차

1. 개요

분석 배경
분석 목적
분석 방향성

2. 1차 EDA

데이터 설명
데이터 전처리
분석 결과

3. 머신러닝 모델 개발

Feature Engineering
모델 예측 결과
모델 선택
속성 중요도

4. 2차 EDA

데이터 전처리
분석 결과
인사이트 요약

5. 결론

인사이트별 전략 제안
한계점
추가 분석 제안

프로젝트 개요

분석 배경

대내적 상황

지점 현황

9개

3년간 3일 체험 고객 수

6,534명




초기
스타트업

대외적 상황

글로벌 공유 오피스 개수·이용자 수

(단위: 개, 만명)



자료: Coworking Resources, SK증권

출처: 서울경제

비용 절감, 이용 편의성으로 공유 오피스 수요 증가



스타트업, 프리랜서 중심으로 빠르게 확산



소수 글로벌 기업의 시장 독점



고객 확보를 위한 차별화된 전략 필요

분석 목적

머신러닝 모델을 통해 고객 행동 패턴을 분석하고



결제 전환에 영향을 미치는 **핵심 요인을 파악**하여



그에 기반한 **비즈니스 전략** 제안

1

고객 이용 패턴 분석

고객의 공유 오피스의 이용
패턴 파악 및 주요 지표 탐색

2

머신러닝 모델 개발

주요 지표 기반 머신러닝
예측 모델 개발 및 검증

3

인사이트 도출

머신러닝 예측 결과를 바탕으로
중요 속성 집중 분석

4

맞춤 전략 제안

중요 속성 분석 결과 기반 고객
맞춤 전략 제안

1차 EDA

trial_register

컬럼명	Type	설명
user_id	INTEGER	유저id
timestamp	TIMESTAMP	3일체험 신청시각

trial_payment

컬럼명	Type	설명
user_id	INTEGER	
is_payment	BOOLEAN	결제 시 : 1, 미결제시 : 0

site_area

컬럼명	Type	설명
site_id	INTEGER	지점id
area	INTEGER	지점 면적

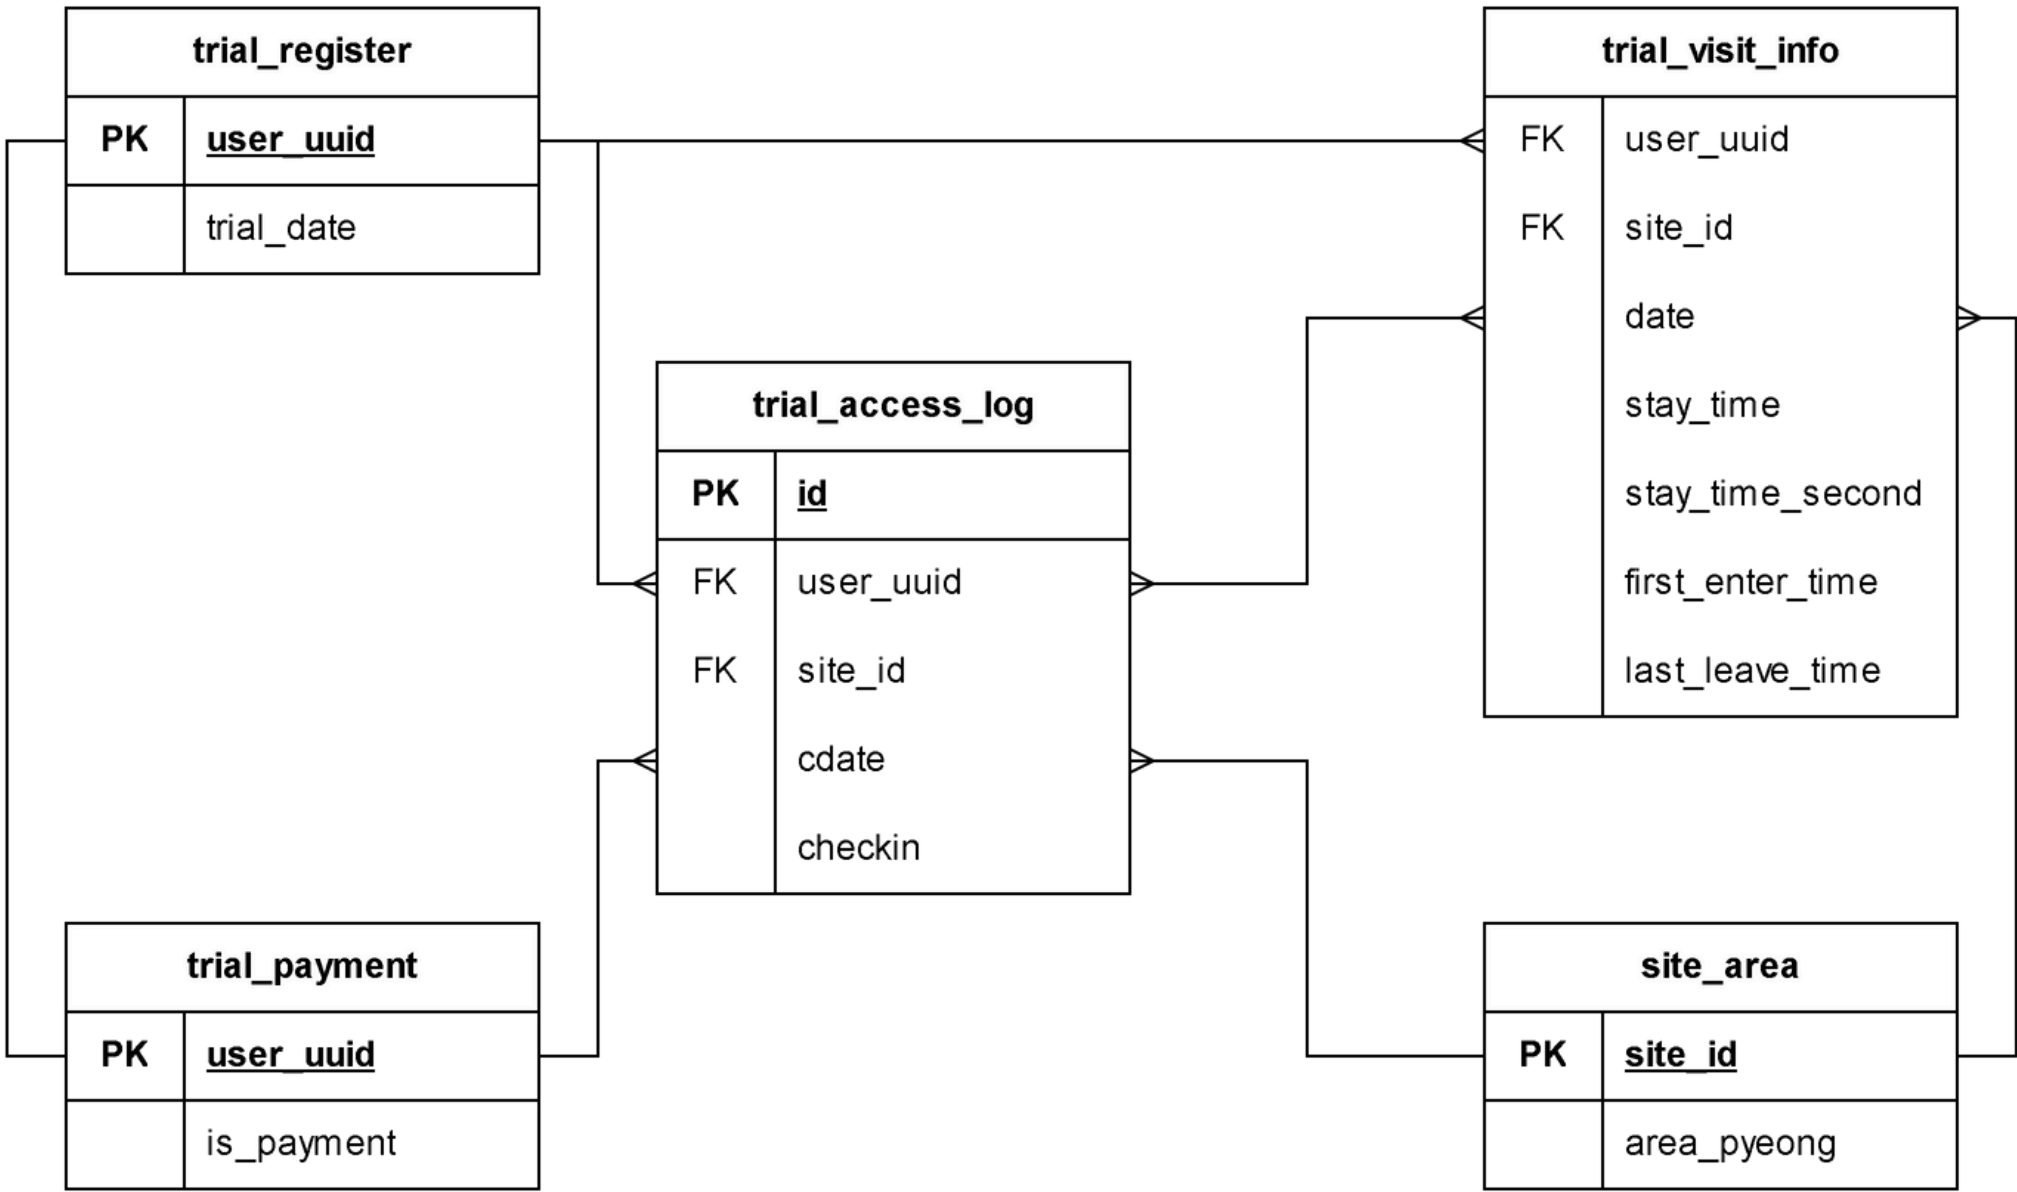
trial_access_log

컬럼명	Type	설명
user_id	INTEGER	
site_id	INTEGER	지점 id
timestamp	TIMESTAMP	출입 로그 생성 시각
checkin	INTEGER	입실 : 1, 퇴실 : 0

trial_visit_info

컬럼명	Type	설명
date	DATE	이용날짜(KST)
user_id	INTEGER	user_id
stay_time	TIME	재실시간
site_id	INTEGER	지점 id
stay_time_second	INTEGER	재실시간 초단위
first_enter_time	TIMESTAMP	해당일자 첫 입실 시각 (KST)
last_leave_time	TIMESTAMP	해당일자 마지막 퇴실 시각 (KST)

Entity Relationship Diagram



- 데이터 테이블 총 5개 - **3일 체험 관련 고객의 이용 패턴 데이터**
- USER ID, SITE ID 기준으로 데이터 JOIN 가능

EDA 진행 과정

- ✓ 결측치, 중복값 처리
- ✓ 시계열 데이터를 중심으로 인사이트 도출
- ✓ 결제 전환에 유의미한 영향이 있을 것으로 예상되는 변수 확인

1) 결측치, 중복값 처리

site_area, trial_access_log, trial_payment, trial_register 이 4개의 테이블 결측치 없음

trial_payment

- 데이터 값이 **결제 = 1, 미결제 = 0** 이기 때문에 user_uuid 중복 불가
→ 모든 컬럼에서 데이터가 동일한 **중복 데이터 제거**

trial_visit_info

- first_enter_time / last_leave_time에서 555개의 결측치 발생
- 해당 컬럼 외 데이터를 보존하기 위해 결측치 유지하기로 결정
- 일자별, 고객별 중복값은 존재하면 안되므로 'date','user_uuid' 기준 **중복값 제거**

trial_register


- 같은 날 2번 3일 체험을 신청하거나, 다른 날짜로 총 2번 3일 체험을 신청한 데이터 존재하여 **중복 데이터 발생**
- 고객별 3일 체험은 1회로 한정되어있으므로 USER_ID 중복 불가
→ 가장 최근 신청 데이터만 남기고 **중복 데이터 제거**

trial_access_log

- **가장 최신 일자 데이터**만 남겨두고 USER_ID를 기준으로 **중복값 제거**


trial_register

월별 신청 고객수



trial_access_log

월별 이용 고객수




하반기(3~4분기)에 신청자 수가 많음

- 8~9월에 3일 체험 신청이 가장 많음
- 이용자 수가 가장 많은 12월의 3일 체험 신청 수는 9월보다 적음
- 12월의 순 이용자 수가 높은 것을 알 수 있음

trial_register

요일별 고유 신청자 수




- 평일의 신청자 수는 주말보다 평균적으로 약 2.1배 많음
- 월요일에 체험 신청을 하는 고객 수가 가장 많음



trial_visit_info

요일별 첫방문을 한 고객수




- 첫 방문 고객 수는 화요일 > 수요일 > 목요일 순으로 많으며, 주중에 집중되고 주말에는 감소하는 경향이 있음

3일 체험의 신청과 방문이 주중에 발생한다

trial_visit_info


시간대별 방문 고객 수 및 결제 고객 수



평일에 첫 방문을 하는 경우

- 오전 9, 10시에 **증가** -> 11시에 소폭 **감소** -> 13~15시 **증가**
-> 15시에 **급감**하는 **M자 형태**의 패턴을 보임

※ 일주일의 패턴을 분석한 결과 평일과 주말은 각각 유사한 패턴을 보임
위 그래프는 평일과 주말의 경향성을 잘 나타내는 그래프로 선정하여 첨부




주말에 첫 방문을 하는 경우

- 오후 12시에서 14시 사이에 고객들이 가장 많이 방문하는 경향이 뚜렷함
- 오전에 완만하게 상승하여 약 14시를 기준으로 하강하는 **종모양** 패턴을 보임
- 주말 오전 시간대의 방문자 수가 적다는 점은 고객들이 여유롭게 방문함을 의미

trial_visit_info

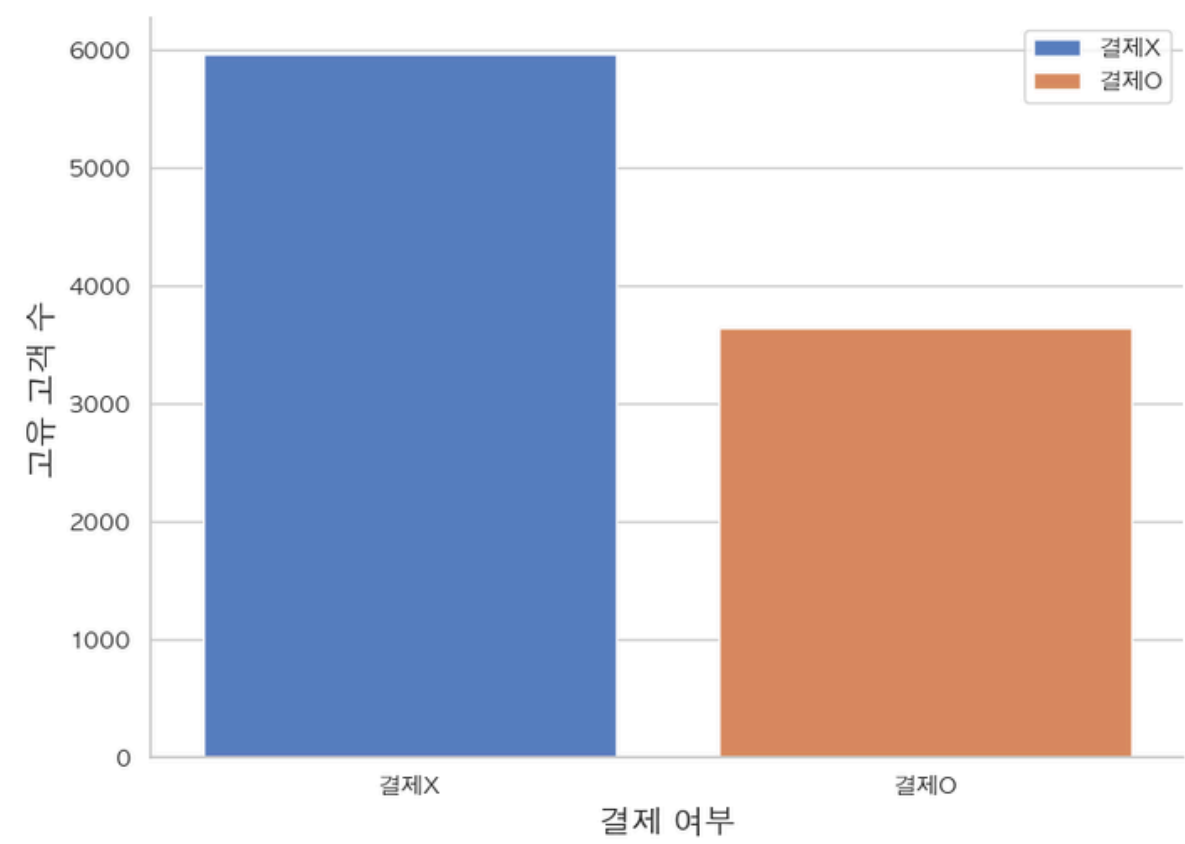
체험 기간 내 방문 일수에 따른 고객 수



- 3일 체험은 72시간을 기준으로 제공되어 방문일수가 최대 4일인 고객이 있다는 것을 확인
- 체험 이용일수는 **1일 > 2일 > 3일 > 4일** 순으로, **하루** 또는 **이틀만 이용한 고객 비율이 가장 높음**
- 고객 확보를 위해 **체험 기간 초반에 결제할 수 있도록** 혜택을 제공하는 등의 유도 전략이 효과적일 것으로 예상됨

trial_payment


결제 여부에 따른 고객수 비교



결제 여부 별 데이터 불균형 존재

- 미결제 고객이 결제 고객보다 약 2배 더 많이 존재
- 결제 전환 여부를 종속변수로 사용시 오버샘플링이 요구됨

월별 결제 비율 추이




월별 결제 전환율 편차 존재

- 5월에 등록된 인원이 가장 많은 결제 전환을 보임
- 9월과 12월은 결제 전환이 거의 없음

trial_access_log


분기별 출입 횟수



하반기(3~4분기)에 3일 체험 고객의 출입이 많음

- 하반기에 서비스에 대한 잠재 고객의 증가가 관찰됨
- **따라서** 체험 고객을 결제 단계까지 도달하기 위한 액션이 필요

요일별 출입 횟수




주말보다 평일에 이용자 출입이 많음

- 공유 오피스를 이용하는 고객들도 워크타임에 맞춰 사용하는 패턴이 관찰됨
- 3일 체험 기간이 대부분 평일에 소진되는 것으로 예상

site_area

지점별 입퇴실 총횟수



평수	지점ID
150 평	3, 5, 6
100 평	2, 4
50 평	1, 17, 47, 49

150평인 지점 3과 6의 입실 횟수가 다른 지점에 비해 높음

- 하지만 150평인 지점 2와 5는 50평인 1지점보다 입실 횟수가 낮음

머신러닝 모델 개발


- ✓ 1차 EDA 결과를 기반으로 주요 예측 변수 설정
- ✓ trial_register, trial_visit_info 데이터에서 시계열 관련 파생변수(월, 요일, 계절, 분기) 생성
- ✓ trial_access_log 데이터에서 고객 출입 패턴 관련 파생변수(입퇴실별 출입횟수, 총 출입횟수) 생성

1) 결측치, 중복값 처리

trial_register **trial_visit_info**

- 1차 EDA 랑 동일하게 반영


2) 파생 변수 생성




월



요일



계절



분기

3) 데이터 테이블 병합

trial_register **trial_access_log** **trial_visit_info**

- trial_register - 고객별 3일 체험 신청 데이터
- trial_access_log - 고객별 출입(입퇴실) 데이터
- trial_visit_info - 고객의 첫 방문 데이터

- ✓ 병합 과정에서 발생한 결측값은 최대한 많은 데이터를 보존하기 위해 연속형 변수는 '0'으로, 범주형 변수는 'unknown'으로 대체함
- ✓ 대체한 결측치 데이터는 모델 학습 시 활용 여부를 결정하여 학습에 반영함
- ✓ is_payment를 종속변수로 설정하고, 종속변수의 불균형을 고려하여 모델 성능 비교 지표로 Accuracy와 함께 F1 Score를 사용함

원본 데이터	trial_register	trial_access_log	trial_visit_info		site_area		trial_payment
기준변수	trial_date	checkin	date	stay_time_second	site_id	area_pyeong	is_payment
파생변수	user_uuid register_quarter register_month register_weekday register_season	access_count access_in_count access_out_count	visit_date_count visit_quarter visit_month visit_weekday visit_season	sum_stay_time_second	site_id site_count	-	-
설명	3일 체험 등록 고객 기준	고객별 입퇴실 출입 횟수	고객별 첫 방문일 기준	고객별 총 체류시간(초)	고객별 방문 지점 갯수	지점규모	결제여부 (종속변수)

RandomForest

테스트 차수	결측치 처리	encoding	파라미터 튜닝	SMOTE	교차검증	Accuracy	F1 Score	비고
1	‘unknown’ 대체	one-hot	O	O	-	0.5974	0.3684	
2	‘unknown’ 대체	Cyclic	O	O	-	0.6073	0.3333	
3	삭제	one-hot	O	O	-	0.6014	0.3154	
4	삭제	Cyclic	O	O	-	0.6213	0.3247	
5	삭제	Cyclic	O	O	-	0.6174	0.3298	access_count, site_id 제거
6	삭제	Cyclic	O	O	-	0.6190	0.3482	weekday 관련 컬럼을 주중, 주말로 이진 분류

- one-hot encoding 보단 cyclic encoding이 Accuracy가 더 높음
- **SMOTETomek** 을 사용해 데이터 불균형을 해소하는 방식으로 모델 성능을 개선
- 데이터의 분균형을 고려했을 때, Accuracy와 F1 Score가 균형하게 높은 6차시가 가장 성능이 좋다고 판단

CatBoost

테스트 차수	결측치 처리	encoding	파라미터 튜닝	SMOTE	교차검증	Accuracy	F1 Score	비고
1	‘unknown’ 대체	-	X	X	-	0.6364	0.3110	
2	‘unknown’ 대체	-	O	X	-	0.6473	0.2691	
3	‘unknown’ 대체	-	O	O	-	0.6338	0.3526	
4	삭제	-	X	X	-	0.6236	0.4266	
5	삭제	-	O	X	-	0.6350	0.3310	
6	삭제	-	O	O	-	0.6251	0.3995	

- 내부적으로 적절한 변환을 수행함으로 별도의 인코딩이 필요 없음
- SMOTE를 사용해 데이터 불균형을 해소하고, 하이퍼파라미터 튜닝을 통해 모델 성능을 개선
- 데이터의 분균형을 고려했을 때, Accuracy와 F1 Score가 균형하게 높은 4차시가 가장 성능이 좋다고 판단

XGBoost

테스트 차수	결측치 처리	encoding	파라미터 튜닝	SMOTE	교차검증	Accuracy	F1 Score	비고
1	‘unknown’ 대체	one-hot	X	X	X	0.6153	0.3238	
2	‘unknown’ 대체	one-hot	X	O	X	0.5834	0.4129	
3	‘unknown’ 대체	one-hot	O	X	O	0.6337	0.2560	
4	‘unknown’ 대체	one-hot	O	O	O	0.5921	0.4008	
5	삭제	Cyclic & one-hot	X	X	X	0.6104	0.4382	
6	삭제	Cyclic & one-hot	X	O	X	0.6053	0.4399	
7	삭제	Cyclic & one-hot	O	X	O	0.6303	0.2424	
8	삭제	Cyclic & one-hot	O	O	O	0.6425	0.3856	

- One-Hot Encoding만 사용했을 때보다 Cyclic Encoding과 함께 사용했을 때 Accuracy 가 높음
- XGBoost 모델에서는 **SMOTE**를 적용했을 때 오히려 모델 성능을 저하시킴
- 데이터의 분균형을 고려했을 때, Accuracy와 F1 Score가 균형하게 높은 5차시가 가장 성능이 좋다고 판단

LightGBM

테스트 차수	결측치 처리	encoding	파라미터 튜닝	SMOTE	교차검증	Accuracy	F1 Score	비고
1	‘unknown’ 대체	one-hot	X	O	-	0.5800	0.4140	‘user_uuid’, ‘site_id’ 삭제
2	‘unknown’ 대체	Cyclic	X	O	-	0.5910	0.3840	‘user_uuid’, ‘site_id’ 삭제
3	삭제	one-hot	X	O	-	0.6040	0.4060	‘user_uuid’, ‘site_id’ 삭제
4	삭제	Cyclic	X	O	-	0.6250	0.7600	‘user_uuid’, ‘site_id’ 삭제
5	삭제	Cyclic & one-hot	X	O	-	0.6090	0.4330	‘user_uuid’, ‘site_id’ 삭제

- one-hot encoding 보다 Cyclic encoding이 Accuracy 가 높음
- 데이터 내 **무의미한 변수를 삭제**하고, 데이터 분균형을 해소 하기위해 **SMOTE**를 사용하여 모델 성능을 개선
- 데이터의 분균형을 고려했을 때, Accuracy와 F1 Score가 균형하게 높은 4차시가 가장 성능이 좋다고 판단


✓ 모든 모델의 성능 테스트에서 결측치 대체값(‘unknown’)의 존재가 모델 성능을 저하시키는 것으로 확인

머신러닝 모델	결측치 처리	encoding	파라미터 튜닝	SMOTE	교차검증	Highest Accuracy	Best Accuracy	Best F1 Score
RandomForest	삭제	Cyclic	O	O	-	0.6213	0.6190	0.3482
CatBoost	삭제	-	X	X	-	0.6473	0.6236	0.4266
XGBoost	삭제	Cyclic & one-hot	X	X	X	0.6425	0.6104	0.4382
LightGBM	삭제	Cyclic	X	O	-	0.6250	0.6250	0.7600

- 각 모델별 Accuracy는 약 60%대로 비슷함
- Accuracy를 높이는 것에만 집중하기보다는 데이터 불균형을 해결할 수 있는 F1-Score를 복합적으로 고려

Accuracy와 F1 Score가 균형하게 높은 LightGBM 모델로 선택

- ✓ sum_stay_time_second 변수의 중요도가 압도적으로 높음
- ✓ 다음 속성과 중요도 차이가 뚜렷해지는 register_month 까지만 집중 분석



2차 EDA

3일 체험 신청 요일/월

- ✓ trial_visit_info, trial_register 데이터 결측치, 중복값 처리
- ✓ 위 2개의 데이터 테이블 및 trial_payment 데이터 병합
- ✓ 시계열 관련 파생변수(신청 월, 신청 요일) 생성

1) 결측치, 중복값 처리

trial_visit_info

- 머신러닝 모델 학습 결과에 따른 **결측치** 처리
- Unknown으로 처리한 결측치 제거
 - 3일 체험 신청했으나 방문하지 않은 고객

trial_register


- 고객별 3일 체험은 1회로 한정되어 있으므로 USER ID 중복 불가
- 따라서 **중복 데이터** 중 마지막 데이터만 남기고 **제거**

2) 데이터 테이블 병합



- trial_visit_info - 머신러닝 모델 학습에 활용된 고객만 선별하기 위해
- trial_register - 고객별 3일 체험 신청 요일 데이터
- trial_payment - 고객별 결제 전환 여부 데이터

3) 파생 변수 생성



월




요일

오피스 방문 요일

총 출입 횟수

- ✓ 머신러닝 학습에 이용했던 데이터를 그대로 사용
- ✓ 총 출입 횟수(access_count)는 연속형 변수이므로 사분위수로 이상치 제거

이상치 박스플롯




총 체류 시간

- ✓ 사분위수로 대략적인 이상치 확인
- ✓ 총 체류시간 데이터 분포 확인 후 KNN 알고리즘으로 이상치 대치
- ✓ 결제 데이터 중복값 제거 후 총 체류시간 데이터와 병합하여 분석 진행


이상치 처리 - KNN 알고리즘

총 체류시간 Boxplot




- 사분위수를 활용한 이상치 탐지 결과 이상치 많지 않음
- 예측 모델 개발을 위해서는 데이터를 최대한 보존하는 것이 좋다고 판단
 - 따라서 KNN 알고리즘을 통해 이상치 대치

유저별 총 체류시간 분포




- 데이터의 분포가 한쪽으로 치우쳐진 형태
 - 긴 꼬리 부분의 정상 데이터 보호를 위해 **90% 기준으로 이상치 선별**
- 최근접 이웃들의 평균으로 이상치를 대치

월별 이용 고객의 총 출입 횟수 및 전환율



- 월별 이용 고객 수 추이를 보면 **상반기보다 하반기에** 상대적으로 많은 사람이 이용한다.

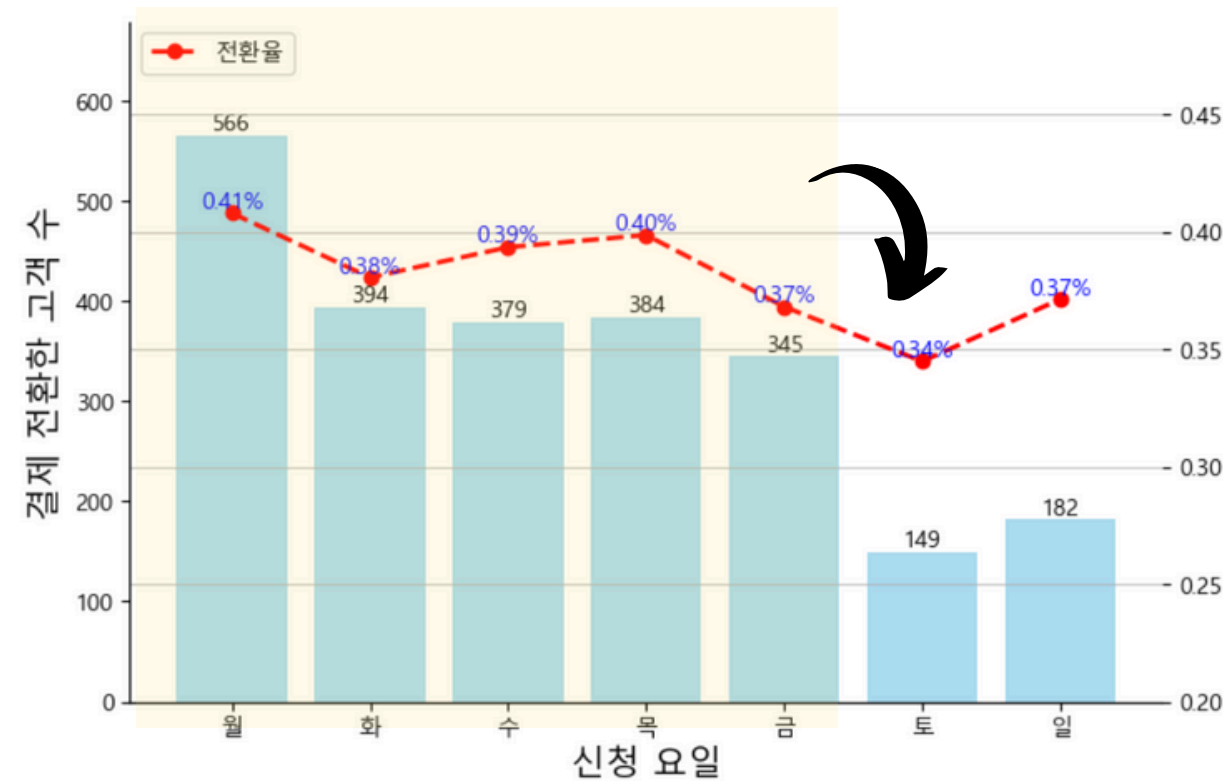
월별 3일 체험 신청 고객 중 결제 전환 고객 수 차이




- 출입 횟수 추이와 동일하게 **상반기보다 하반기에** 상대적으로 **더 많이 결제**했다는 사실을 알 수 있다.

하반기에 3일 체험으로 서비스를 이용하는 고객과 결제 전환 고객 모두 증가한다.

요일별 3일 체험 신청 고객 중 결제 전환 고객 수 및 전환율 추이




요일별 최초 방문 고객 중 결제 전환 고객 수 추이



- 3일 체험 신청 및 첫 방문 데이터의 요일별 결제 전환 고객 수가 주말보다 평일이 현저하게 높다.
- 평일과 주말의 3일 체험을 신청한 결제 전환 고객 수 차이는 크지만, 결제 전환율은 비교적 차이가 크지 않다. (좌측 그래프)
- 결제 전환 고객은 화, 수, 목, 금부터 주로 이용을 시작하는 패턴이 관찰된다. (우측 그래프)
→ **평일과 주말별 차별화된 전략이 요구된다.**

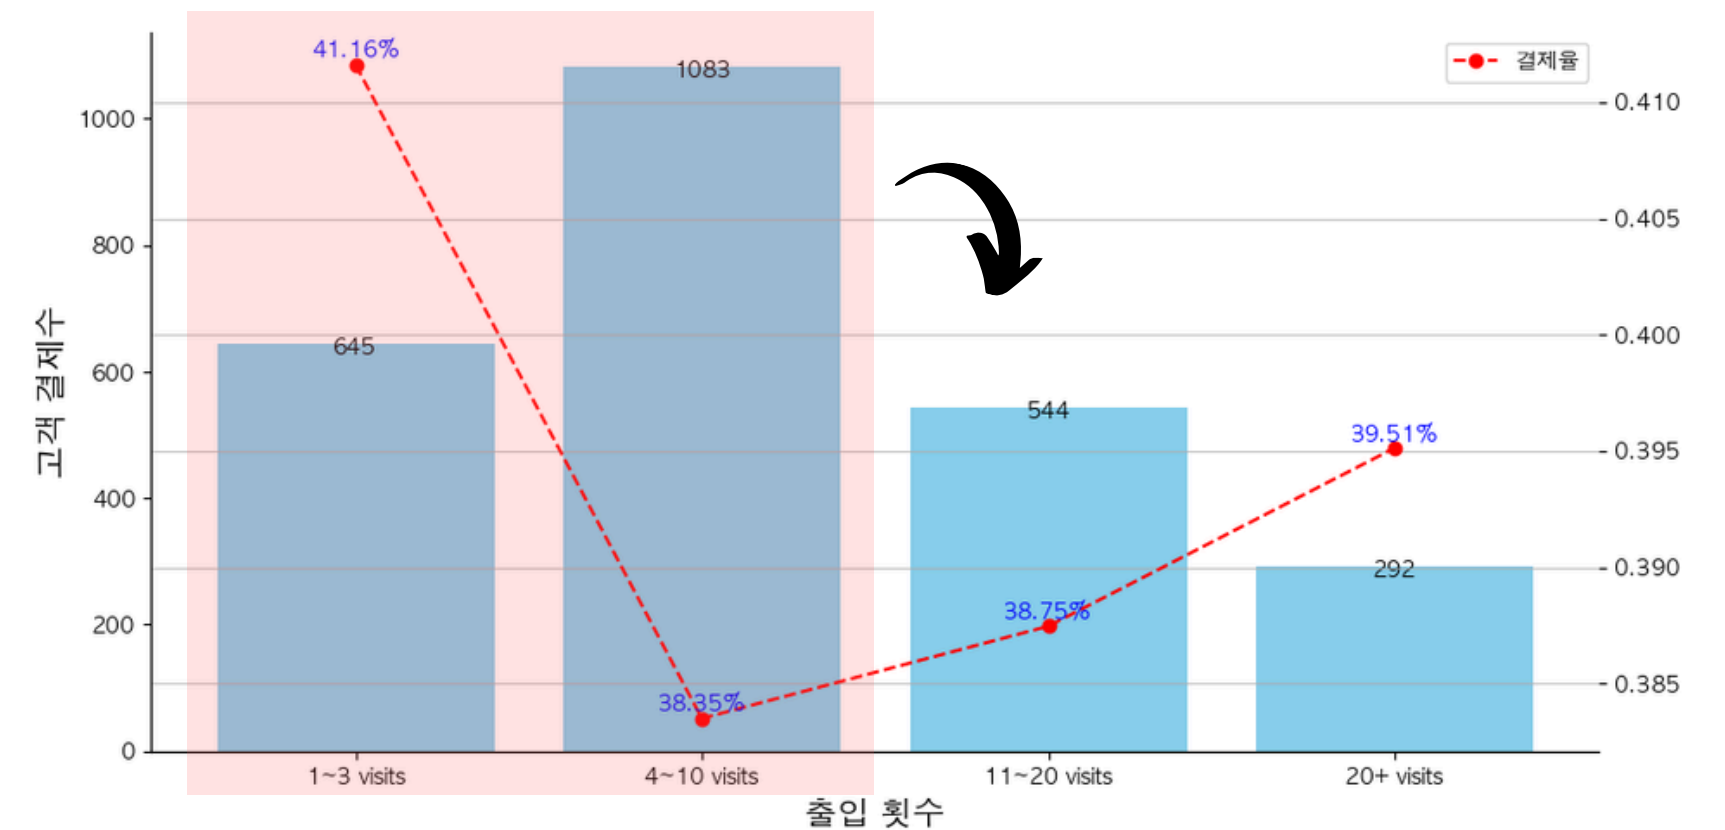
3일 체험 신청일 & 첫 방문일에서 평일과 주말의 결제 고객 수 차이가 뚜렷하다.

체류시간별 전환율 이동 평균 및 결제자 수 추이



- 결제자 수 체류시간 **3시간 기준 급격히 증가 후 감소**하는 패턴 관찰
- 대부분 3시간 정도 경험하고 결제 여부를 결정(결제 or 이탈)
- 가장 전환율이 높은 시간은 이용한지 **15시간**이 될 때
- 변동성(노란색 영역)이 커지는 **27시간** 기준으로 데이터 필터링

출입 횟수별 결제 고객 수 추이



- 결제 전환 고객은 **방문 초기(10회 출입 이하)**에 몰려 있음
- 4~10회 출입 구간에 결제 고객 수는 많지만 결제 전환율은 낮음
→ **이 구간에서 결제하거나 이탈하는 의사결정**이 이루어지는 것으로 추정

3일 체험 기간 중 주로 이용 3시간 전후로 결제 의사결정을 내리며, 15시간에서 전환율이 가장 높다.

인사이트 1)

하반기에 3일 체험으로 서비스를 이용하는 고객과 결제 전환 고객 모두 증가한다.

인사이트 2)

3일 체험 신청일 & 첫 방문일에서 **평일과 주말의 결제 고객 수 차이**가 뚜렷하다.

인사이트 3)

3일 체험 기간 중 주로 이용 **3시간 전후**로 결제 의사결정을 내리며, **15시간**에서 전환율이 가장 높다.

결론

하반기에 3일 체험으로 서비스를 이용하는 고객과 결제 전환 고객 모두 증가한다.

- ✓ 하반기에 3일 체험 및 결제 전환 고객이 모두 증가하므로 이를 극대화할 필요성 존재
- ✓ 분기별 시기를 고려한 맞춤 프로모션 진행하여 결제 전환 극대화 전략

집중 프로모션

3Q

휴가시즌

신학기 분기말 9월

특성

- 7~8월은 휴가 시즌, 업무 공간 수요 비교적 적음
- 9월부터 신학기, 분기말 업무 증가, 창업 준비 증가 등으로 오피스 이용 수요가 다시 증가(출입 횟수 크게 증가)

전략

7~8월에 단기로 고객을 유지시켜 9월까지 연결시키고,
9월에 장기 고객 확보 프로모션으로 연말까지 락인

기대효과

여름철 단기 이용 고객 전환 + 9월부터 장기 고객 확보

4Q

연말시즌

연말 이탈 방지

특성

- 10~11월은 하반기 목표 달성을 위한 업무 공간 수요 증가
- 12월은 연말 정산 & 홀리데이 시즌으로 정기 고객 유지 및 신규 고객 유입 극대화 필요

전략

연말까지 지속적으로 이용할 수 있는 이용 플랜(2~3개월) 유도 +
새해 프로모션으로 이탈 방지(내년으로 연결되도록)

기대효과

하반기 업무 집중 고객 유치 + 연말 고객 락인 효과

3일 체험 신청일 & 첫 방문일에서 평일과 주말의 결제 고객 수 차이가 뚜렷하다.

✓ 평일 방문 고객과 주말 방문 고객을 별도의 타겟으로 차별화된 마케팅 전략

1) 평일 방문 고객 대상



- 월요일에 3일 체험 신청하고 화~목 중 방문하는 고객 대상 **금요일 프리미엄 데이 패스** 제공하여 추가 방문 유도
- **금요일 방문 후 즉시 결제 시 추가 할인**



- 화~목 방문 고객 및 기존 고객 대상 스타트업 **네트워킹 데이, 공유 오피스 활용 전략 등의 이벤트**를 통해 공유 오피스 서비스 가치 체험 기회 제공
- **이벤트 참여 시 결제 할인 쿠폰 제공**

기대효과 : 월요일에 3일 체험 신청 후 화~목요일에 방문하여 결제하는 고객이 많으므로, 평일 재방문을 유도하는 혜택 및 이벤트를 통해 고객의 서비스 만족도를 높일 수 있을 것으로 기대됩니다.

2) 주말 방문 고객 대상



- 프리랜서, 대학생, 시험 준비생 등 주말에 집중이 필요한 고객 대상 **조용한 업무 환경을 강조하는 마케팅**
- 주말만 이용 가능한 **주말 전용 요금제**를 도입하여 결제 금액 부담 해소



- 주말에 3일 체험 첫 방문을 한 고객 대상 **평일 추가 1일 무료 체험** 서비스 제공하여 주말에 이어 평일까지 재방문 유도

기대효과 : 평일 보다 조용한 환경을 원하는 고객에게 주말 전용 요금제로 결제 금액의 부담감을 완화시키고, 평일 무료 체험권과 같은 주말 방문자 한정 혜택을 제공하여 고객의 만족도가 향상될 것으로 기대됩니다.

대부분의 고객은 이용 3시간 전후로 결제 의사결정을 내리며 15시간에서 전환율이 가장 높다.

1) 단 기간에 경험할 수 있는 가치 제공

체험일 별 차등 할인 프로모션

빠른 결제 유도

가장 강력한 소구점



- 체험 기간 3일 중 결제일에 따라 추가 할인 차등 적용
 - ex. 첫날 결제시 15% 할인 / 둘째날 결제시 10% 할인 등

기대효과 : 3시간 전후로 결제를 결정하는 고객이 많으므로, 빠르게 결제할수록 높은 할인 혜택을 제공하여 고객의 고민을 덜어줄 것으로 기대됩니다.

오피스 투어 / 베스트 이용 플랜 추천

고객 만족도

고객 중심

무형의 가치



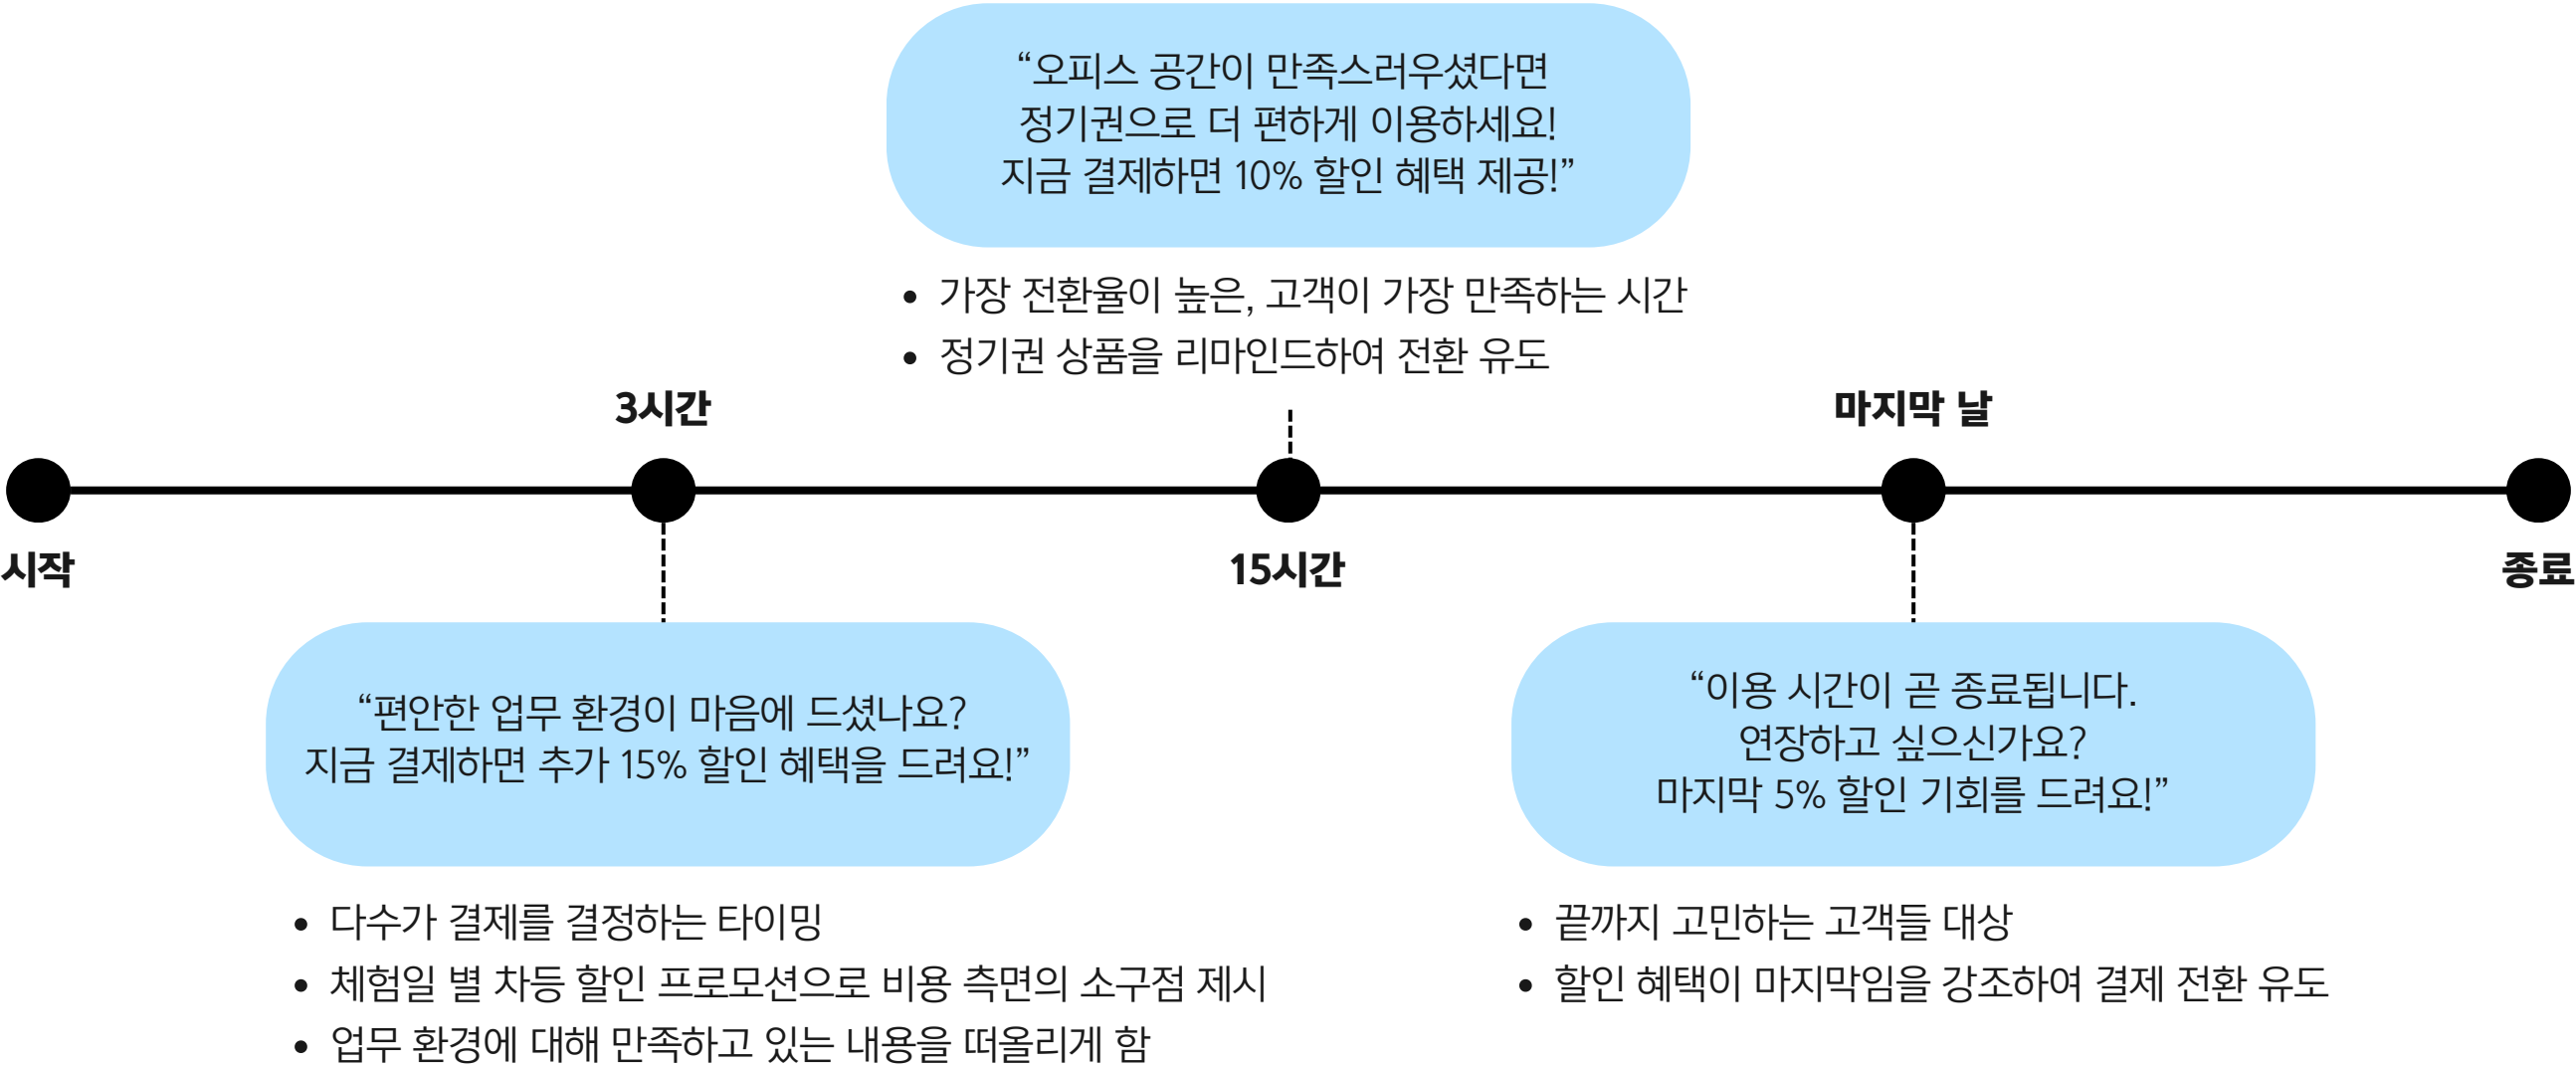
- 첫 방문 시 오피스 투어 진행(좌석, 회의실, 편의시설 설명)
- 체험 고객에게 베스트 이용 플랜 추천
 - ex. 목적별 공간 추천 / 요금 플랜 추천

기대효과 : 고객이 환영받는 느낌의 서비스를 제공함으로써 오피스에 대해 좋은 첫 인상을 남겨 단 기간에 고객 서비스 및 오피스 공간에 대한 가치를 느끼게 합니다.

대부분의 고객은 이용 3시간 전후로 결제 의사결정을 내리며 15시간에서 전환율이 가장 높다.

2) 이용 시간에 따른 CRM

- 전용앱 푸시 알림
- 카카오톡 / 문자 메시지 / 이메일



기대효과 : 데이터 분석을 통해 도출한, 결제 전환에 의미있는 이용 시간대에 적절한 메시지를 고객에게 전달함으로써 결제 전환이 유도될 것이라고 기대됩니다.

분석의 한계점

결제 시점 데이터 부족

결제 시점의 데이터 부족으로 고객의 서비스 이용 결정 시점을 추정할 수 없어
고객의 이용 기간에 따른 결제 전환율을 확인 할 수 없었음

지점 상세 정보 부족

지점의 위치, 구비 시설, 특징 등 지점 정보가 충분하지 않아 지점별 이용 고객의
결제 및 이탈 원인을 파악하기 어려움

동일한 Feature 들로만 모델 최적화

동일한 Feature들로만 머신러닝 모델 최적화를 시도하여 모델 성능에 한계 존재

추가 분석 제안

추가 데이터 활용하여 모델 개선

- 지점별 근처 교통편 등 외부 데이터 활용하여 Feature 추가
- 내부의 지점별 특이사항(커피머신, 안마의자 여부 등) 관련 데이터로 Feature 생성

체험 고객 만족도 수집

- 3일 체험 종료 시점에 서비스 만족도에 대한 설문조사 진행
- 결과를 결제 여부에 따라 분류하고 비교 분석 진행하여 서비스 개선에 활용

고객 세그먼트 분석

- 머신러닝 모델 중 주요 Feature로 클러스터링 실시하여 클러스터별 분석 진행
- 결제 고객들의 요금 플랜 데이터를 추가하여 RFM 분석 진행